

REGRESSÃO LINEAR MÚLTIPLA

Regressão Múltipla

Se tivermos mais de uma variável independente, usamos a regressão múltipla.

A regressão múltipla nos permite explorar como várias variáveis independentes influenciam a variável dependente.

O que mais pode influenciar o preço de uma casa além do seu tamanho?

Vamos usar metros quadrados, número de quartos e número de banheiros

Regressão Múltipla

$$\hat{y} = b_0 + b_1 x_1 + b_2 x_2 + b_3 x_3$$

Onde $\hat{y}$ = preço da casa estimado, x_1 = metros quadrados, x_2 = número de quartos, x_3 = número de banheiros

Por que colocamos todas as variáveis na mesma equação?

Porque assim podemos isolar o impacto de cada variável no preço da casa individualmente, encontrando o efeito real de cada variável no preço.

INTERPRETAÇÃO DOS COEFICIENTES

Exemplo: Preço de uma casa

$$\widehat{Preço} = 154.070 + 1.030 m^2 + 479 Quartos + 92.145 Banheiros$$

Intercepto:

Interpretar o intercepto não faz sentido (preço de uma casa com zero m2, zero quartos e zero banheiros).

Custo fixo: R\$154.070

Exemplo: Preço de uma casa

$$\widehat{\text{Preço}} = 154.070 + 1.030 m^2 + 479 \text{ Quartos} + 92.145 \text{ Banheiros}$$

- O preço aumenta em R\$1.030 por m^2 entre casas com o mesmo número de quartos e banheiros.
- O preço aumenta em R\$479 por quarto entre casas com o mesmo número de m^2 e banheiros.
- O preço aumenta em R\$92.145 por banheiro entre casas com o mesmo número de m^2 e quartos.

PREVISÃO

Exemplo: Preço de uma casa

Qual o preço médio de uma casa com 150 metros quadrados, 3 quartos e 2 banheiros?

$$\widehat{Preço} = 154.070 + 1.030 \, m^2 + 479 \, Quartos + 92.145 \, Banheiros$$

$$\widehat{Preço} = 154.070 + 1030 \cdot 150 + 479 \cdot 3 + 92145 \cdot 2$$

$$\widehat{Preço} = 494.297$$

O preço estimado é, em média, R\$494.297.

ENTENDENDO A REGRESSÃO MÚLTIPLA

Exemplo: Loja de roupas

Quero identificar como duas variáveis influenciam as vendas em uma rede de lojas de roupas femininas:

- Estar em uma região mais rica.
- Estar em um shopping com menos concorrentes.

Exemplo: Loja de roupas


Variável dependente (y):

- Vendas anuais nas lojas de uma rede de roupas femininas (em dólares por pés ao quadrado do tamanho da loja).

Duas variáveis independentes (x):

- A mediana da renda familiar na área (em US\$ 1,000).
- Número de lojas de roupas concorrentes no mesmo shopping.

Exemplo: Loja de roupas



	Sales	Income	Competitors
Sales	1.0000	0.7080	0.0666
Income	0.7080	1.0000	0.4743
Competitors	0.0666	0.4743	1.0000

Exemplo: Loja de roupas

Se fossemos analisar duas regressões simples, elas seriam:

$$\widehat{\text{Vendas}} = 97,07 + 6,46 \text{ Renda}$$

$$\widehat{\text{Vendas}} = 502,20 + 4,64 \text{ Concorrentes}$$

$b_1 = 6,46$: a loja que está em uma área com uma renda de US\$ 1.000 a mais vende, em média, US\$ 6,46 a mais por pé quadrado.

$b_1 = 4,64$: cada concorrente adicional aumenta as vendas em média de US\$ 4,64 por pé quadrado.

Exemplo: Loja de roupas

Ao fazer a análise de regressão, obtemos a seguinte equação:

$$\widehat{\text{Vendas}} = 60,36 + 7,97 \text{ Renda} - 24,16 \text{ Concorrentes}$$

b1 = 7,97: entre lojas com o mesmo número de concorrente, a loja que está em uma área com uma renda de US\$ 1.000 a mais vende, em média, US\$ 7,97 a mais por pé quadrado.

b2 = -24,16: entre lojas em áreas igualmente ricas, cada concorrente adicional reduz as venda em média de US\$ 24,16 por pé quadrado.

Exemplo: Loja de roupas

Neste exemplo, as inclinações da reta não estão consistentes.

Isso acontece pois as variáveis independentes são correlacionadas.

$$\widehat{\text{Vendas}} = 502,20 + 4,64 \text{ Concorrentes}$$

Na regressão simples, a inclinação é positiva, pois locais mais ricos tendem a atrair mais concorrentes.

A regressão múltipla separa esses efeitos, mas a regressão simples não separa.

MEDIDAS DE ADEQUAÇÃO

Medidas de Adequação

Existem três medidas para julgar quão bem uma equação de regressão se ajusta aos dados.

- Desvio padrão dos resíduos: se
- Coeficiente de determinação: R^2
- R^2 ajustado

Desvio padrão dos resíduos

Desvio padrão dos resíduos mede o quanto os resíduos variam em torno da linha da regressão.

- $0 \leq se < \infty$

Valores próximos de zero indicam um melhor ajuste ($se = 0$ significa uma relação linear perfeita).

Já que pode assumir qualquer valor não negativo, se é melhor usado para comparar o ajuste de dois modelos de regressão diferentes.

Gráfico de calibração

É o gráfico de dispersão da variável dependente y nos valores estimados $\hat{y}$.

R^2 é a correlação entre y e $\hat{y}$: quanto mais agrupado os dados ao longo da linha diagonal no gráfico de calibração, maior será o valor de R^2 .



Coeficiente de determinação: R^2

R^2 : relação linear entre a variável dependente y e os valores estimados da variável dependente $\hat{y}$.

- $0 \leq R^2 \leq 1$

$R^2 = 1$: relação linear perfeita entre a variável dependente e seus valores estimados.

$R^2 = 0$: nenhuma relação linear entre a variável dependente e seus valores estimados.

R^2 Ajustado

Na regressão múltipla, adicionar mais variáveis independentes sempre resulta em um R^2 mais alto.

Algumas dessas variáveis podem não ser importantes e não deveriam estar no modelo, porém elas aumentam o valor de R^2 artificialmente.

O R^2 ajustado “ajusta” este aumento artificial. Deve ser usado para comparar dois modelos com números diferentes de variáveis independentes.

Comparando Modelos

O preço de uma casa depende de outros fatores além dos metros quadrados, incluindo o número de quartos e o número de banheiros. A inclusão dessas variáveis fornecerá um modelo que prevê com mais precisão o preço de uma casa.

Modelo 1: $\widehat{Preço} = b_0 + b_1 m^2$

Modelo 2: $\widehat{Preço} = b_0 + b_1 m^2 + b_2 Quartos$

Modelo 3: $\widehat{Preço} = b_0 + b_1 m^2 + b_2 Quartos + b_3 Banheiros$

Modelo 4: $\widehat{Preço} = b_0 + b_1 Quartos + b_2 Banheiros$

Modelo 5: $\widehat{Preço} = b_0 + b_1 m^2 + b_2 Banheiros$

Qual modelo é melhor?

Métricas	Modelo 1	Modelo 2	Modelo 3	Modelo 4	Modelo 5
R múltiplo	0,78	0,78	0,85	0,81	0,85
R-quadrado	0,60	0,61	0,72	0,66	0,72
R-quadrado ajustado	0,59	0,58	0,70	0,64	0,71
Erro padrão	87183,82	88150,74	74977,29	81863,78	73833,18
	m^2	m^2	m^2	Quartos	m^2
		Quartos	Quartos	Banheiros	Banheiros
			Banheiros		

SUPOSIÇÕES



Suposições

- O modelo de regressão é linear
- Os resíduos são normalmente distribuídos
- Os resíduos tem variância constante
- Os resíduos são independentes
- As variáveis independentes não são correlacionadas umas com as outras (sem multicolinearidade)
- As variáveis independentes não são correlacionadas com o erro (sem endogeneidade)
- Atenção aos outliers

Linearidade

A primeira premissa do modelo de regressão linear é a de que as variáveis dependente e independentes sejam linearmente relacionadas.

Primeiro, analise os gráficos de y vs. cada x_i




Linearidade

Depois, analise o gráfico dos resíduos vs. os valores estimados $\hat{y}$.

A linearidade é justificada se os resíduos forem dispersos aleatoriamente em torno de zero.

Uma tendência é indicativa de padrões não lineares.

Este gráfico residual mostra uma tendência. Logo, o modelo linear seria inadequado.



Solução

Se o gráfico residual exibir um padrão não linear, as inferências feitas por um modelo de regressão linear estarão erradas.

Nesses casos, use transformações não lineares.


Análise dos Resíduos

- 1) Os resíduos são normalmente distribuídos
- 2) Os resíduos tem variância constante (sem heteroscedasticidade)
- 3) Os resíduos são independentes

Normalidade

Verificamos se os resíduos são normalmente distribuídos:



- Q-Q plot
- Teste de normalidade (Shapiro-Wilk)
- Teorema do Limite Central



Variância Constante

Analise o gráfico dos resíduos vs. os valores estimados $\hat{y}$.



Neste exemplo, vemos que a variância não é constante:



Independência

Quando tiver dados de uma série temporal, plote os resíduos em função do tempo para procurar um padrão que indique dependência nos erros.

Use a estatística Durbin-Watson para testar a correlação entre resíduos adjacentes (conhecido como autocorrelação).



SUPOSIÇÕES

Suposições

- O modelo de regressão é linear
- Os resíduos são normalmente distribuídos
- Os resíduos tem variância constante (sem heteroscedasticidade)
- Os resíduos são independentes
- As variáveis independentes não são correlacionadas umas com as outras (sem multicolinearidade)
- As variáveis independentes não são correlacionadas com o erro (sem endogeneidade)
- Atenção aos outliers

Multicolinearidade

A multicolinearidade existe quando duas ou mais variáveis independentes têm uma relação linear forte.

A presença de multicolinearidade resulta em estimativas imprecisas dos coeficientes de inclinação.

Quando acontece, as estimativas não são interpretáveis.

Exemplo:

$\widehat{\text{Perda de peso}} = b_0 + b_1 \text{boa alimentação} + b_2 \text{exercício físico}$

Detectando

O que pode indicar multicolinearidade:

- Sinais aparentemente errados dos coeficientes estimados.
- O modelo ser significativo como um todo mas o teste individual mostra que as variáveis independentes não são significativas.
- VIF: quantifica a quantidade de variação única em cada variável independente e mede o efeito da colinearidade.

VIF

VIF (Fator de Inflação da Variância): quantifica a quantidade de variação única em cada variável independente e mede o efeito da colinearidade (redundância).

O VIF para cada X_j é $VIF(X_j) = \frac{1}{1-R_j^2}$

- $VIF < 5$: sem colinearidade forte
- $5 < VIF < 10$: alta colinearidade
- $VIF > 10$: colinearidade séria, necessita correção

Multicolinearidade: Solução

- Se o objetivo for previsão, pode fazer sentido não fazer nada
- Descartar uma das variáveis colineares
- Aumentar o tamanho da amostra
- Transformar as variáveis
- Agrupar as variáveis usando métodos como Análise Fatorial ou Análise de Componentes Principais

Endogeneidade

Uma suposição é que o termo de erro não seja correlacionado com as variáveis independentes.

Exemplo: o salário de uma pessoa está relacionado à sua habilidade e escolaridade.

Se não pudermos incluir habilidade na regressão, esse fator é incorporado ao termo de erro.

Nesse caso, o modelo pode atribuir incorretamente o efeito da habilidade sobre o salário à escolaridade.

$$\widehat{\text{Salário}} = \beta_0 + \beta_1 \text{escolaridade} + \varepsilon$$

Endogeneidade: Solução

Se possível, faça uma lista das variáveis independentes em potencial antes de estimar a regressão.


Alguns métodos que podem ser usados são: Variáveis Instrumentais, Two-Stage Least Squares (2SLS), Experimentos Naturais, Modelos de Painel com Efeitos Fixos, Diferenças em Diferenças.

Outliers

O outlier é uma observação fora do padrão encontrado nas outras observações na amostra.

Consequências:

- Desvio da linha de regressão
- Aumento do erro padrão



Outliers: Solução

Se o outlier descreve um valor que é esperado da próxima vez sob as mesmas condições, ele deve ser incluído.

Faça a análise de regressão com e sem os outliers e verifique as diferenças entre elas.

TESTES DE SIGNIFICÂNCIA (INFERÊNCIA NA REGRESSÃO)

Testes de Significância

$$\widehat{Preço} = 154.070 + 1.030 m^2 + 479 Quartos + 92.145 Banheiros$$

O que essa equação de regressão da amostra nos diz sobre o modelo populacional?

$$Preço = \beta_0 + \beta_1 m^2 + \beta_2 Quartos + \beta_3 Banheiros + \varepsilon$$

Testes de Significância

Usamos a inferência estatística para realizar três testes:

Teste de significância conjunta

- Verificar se existe uma relação linear entre y e todos os x_i 's.

Teste de significância individual

- Verificar se existe uma relação linear entre y e cada um dos x_i 's

Intervalo de confiança para testar a significância individual

- Verificar o intervalo para o verdadeiro valor dos coeficientes

Teste de significância conjunta

Primeiro verificamos se o modelo de regressão é significativo como um todo.

Testamos se existe uma relação linear entre a variável dependente e pelo menos uma das variáveis independentes.

As hipóteses para um teste de significância conjunta são:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$$

$$H_A: \text{pelo menos um } \beta_j \neq 0$$

Verificamos o teste de hipóteses pelo p-valor do teste F.

Teste de significância individual

Verificamos se existe uma relação linear entre cada x_j e y .

As hipóteses para um teste de significância individual são:

$H_0: \beta_j = 0$ (não há relação linear entre x_j e y)

$H_A: \beta_j \neq 0$ (há uma relação linear entre x_j e y)

Verificamos o teste de hipóteses pelo p-valor do teste t.

Intervalo de Confiança

Também podemos testar se os coeficientes são significativos pelo intervalo de confiança.

Se o intervalo de confiança não incluir 0, então ele dá evidências de que β_j é um preditor significativo da variável dependente

Etapas da regressão múltipla

1. Qual é o problema a ser resolvido? Esses dados ajudam a resolvê-lo?
2. Verifique os gráficos de dispersão da dependente vs. cada variável independente.
3. Se os gráficos de dispersão forem lineares o suficiente, faça a regressão múltipla. Caso contrário, faça uma transformação.
4. Obtenha os resíduos e os valores estimados da regressão.

Etapas da regressão múltipla

5. Faça o gráfico do resíduo vs. valores estimados para verificar variâncias semelhantes.
6. Verifique os resíduos quanto à dependência (série temporal).
7. Procure padrões no gráfico de dispersão dos resíduos vs. cada variável independente.
8. Verifique se os resíduos são aproximadamente normais.

Etapas da regressão múltipla

9. Use a estatística F para o teste de significância conjunta para verificar se existe uma relação linear entre y e todos os x_i 's.
10. Se a estatística F for estatisticamente significativa, teste e interprete a significância individual, para verificar se existe uma relação linear entre y e cada um dos x_i 's.

VARIÁVEIS CATEGÓRICAS BINÁRIAS

Variável Dummy (binária)

Uma variável dummy é uma variável qualitativa que geralmente contém duas categorias (binárias).

Exemplos são: gênero (feminino/masculino), sim/não, comprou/não comprou.

Como temos dois valores, essa variável é codificada como 0 e 1.

Exemplo: Discriminação salarial

Três professores entraram com uma decisão judicial alegando que a Universidade pagava salários mais altos para os professores mais jovens e do sexo masculino.

Mary Schweitzer trabalha no RH e foi convidada para testar se há discriminação salarial por idade e gênero.

Ela reuniu dados de 42 professores, incluindo salário anual (em R\$ 1.000), anos de experiência, o sexo e a idade do professor.

Exemplo

Para medir o impacto do sexo e da idade no salário, precisamos criar duas variáveis dummies, uma para cada variável qualitativa:

Usamos uma variável dummy para categorizar o sexo da seguinte forma:

- $d = 1$, se “masculino”
- $d = 0$, se “feminino”

A variável qualitativa idade (abaixo ou acima de 60 anos) é definida como uma variável dummy da seguinte forma:

- $d = 1$, se idade ≥ 60
- $d = 0$, se idade < 60

Exemplo

O modelo estimado é: $\hat{y} = 3.383 + 94 \text{ Experiência} + 1.160 d_1 + 362 d_2$

A diferença entre professores e professoras é capturada pelo coeficiente em d_1 . Em média, um professor ganha R\$ 1.160 a mais comparando com uma professora (com mesma experiência).

A diferença de salário entre professores mais velhos e mais jovens é capturada pelo coeficiente d_2 .

Professores mais velhos ganham em média R\$ 362 a mais em comparação com os mais jovens (com mesma experiência).

Testando a significância

Para determinar se o salário de um professor do sexo masculino difere do salário de uma professora, olhamos o p-valor do coeficiente.

Fazemos o mesmo para determinar se o salário de um professor mais velho difere do salário de um mais novo, ao nível de significância de 5%.

	<i>Coeficientes</i>	<i>Erro padrão</i>	<i>Stat t</i>	<i>valor-P</i>	<i>95% inferiores</i>	<i>95% superiores</i>
Interseção	3383.35	307.62	11.00	2.27E-13	2760.61	4006.09
Experiência	94.00	14.92	6.30	2.2E-07	63.80	124.20
d1	1160.41	238.86	4.86	2.07E-05	676.87	1643.95
d2	361.89	386.92	0.94	0.355532	-421.39	1145.17

Regressão com gênero

Como a idade não é significativa em estimar o salário, vamos focar no efeito do sexo no salário.

O resultado da regressão usando experiência e sexo nos dá a equação:

$$\hat{y} = 3.286 + 103x + 1.157d$$

Interpretação: Homens ($d = 1$) ganham cerca de R\$1.157 a mais que mulheres ($d = 0$), com o mesmo número de anos de experiência.

	<i>Coeficientes</i>	<i>Erro padrão</i>	<i>Stat t</i>	<i>valor-P</i>	<i>95% inferiores</i>	<i>95% superiores</i>
Interseção	3285.62	288.86	11.37	5.90E-14	2701.34	3869.90
Experiência	103.30	11.10	9.31	1.87E-11	80.85	125.75
Sexo	1157.23	238.45	4.85	1.99E-05	674.92	1639.53

Mais análises

A equação de regressão é $\hat{y} = 3.286 + 103x + 1.157d$

Para homens ($d = 1$), o modelo é:

$$\hat{y} = 3.286 + 103x + 1.157 (1) = 4.443 + 103x$$

Para mulheres ($d = 0$), o modelo é:

$$\hat{y} = 3.286 + 103x + 1.157 (0) = 3.286 + 103x$$

O gráfico da equação linear para homens é igual ao das mulheres com um aumento de 1.157 para todos os valores de x .

Regressão com uma variável dummy

Para $d = 1$, o valor previsto de $\hat{y}$ fica:

$$\hat{y} = b_0 + b_1x + b_2 = (b_0 + b_2) + b_1x$$


Da mesma forma, quando $d = 0$:

$$\hat{y} = b_0 + b_1x$$

Portanto, a variável dummy permite uma mudança no intercepto, permitindo usar uma única equação de regressão para representar ambas as categorias da variável qualitativa.

Interpretação Gráfica

A variável dummy desloca o gráfico da linha de regressão para cima pelo coeficiente da variável dummy (ou para baixo se o coeficiente for negativo).



VARIÁVEIS CATEGÓRICAS MÚLTIPLAS

Variáveis com múltiplas categorias

Algumas variáveis qualitativas podem ter mais de duas categorias.

Nesses casos, usamos várias variáveis dummies para capturar todas as categorias.

Para uma variável qualitativa com mais de duas categorias, incluímos uma variável dummy a menos que o número de categorias da variável qualitativa.

Criando dummies

Vamos criar variáveis dummies para as regiões do Brasil.

Como temos 5 regiões (categorias), teremos 4 variáveis dummies no total: d1, d2, d3 e d4.




Criando dummies

Devemos escolher uma das categorias como “grupo controle” que terá valor 0 em todas as variáveis dummies.

Como escolher? Depende do objetivo da pesquisa. Mas uma boa dica é que quando não está claro qual o grupo controle, podemos adotar a categoria que abrange a maioria das pessoas.

Assim, a região sudeste será a categoria base, uma vez que há uma concentração populacional nesta região.



Criando dummies

De forma arbitrária, defino a região centro-oeste como $d1 = 1$, enquanto as demais regiões recebem $d1 = 0$.



Variável Dummy	
Região	D1
Sudeste	0
Centro-Oeste	1
Nordeste	0
Norte	0
Sul	0

Criando dummies

Defino a região nordeste como $d2 = 1$, enquanto as demais regiões recebem $d2 = 0$.



Região	Variável Dummy	
	D1	D2
Sudeste	0	0
Centro-Oeste	1	0
Nordeste	0	1
Norte	0	0
Sul	0	0

Criando dummies

Repetindo o passo anterior, encontramos as demais variáveis para as regiões norte e sul:

Região	Variável Dummy			
	D1	D2	D3	D4
Sudeste	0	0	0	0
Centro-Oeste	1	0	0	0
Nordeste	0	1	0	0
Norte	0	0	1	0
Sul	0	0	0	1



Meio de transporte

O meio de transporte usado para ir ao trabalho pode ser descrito por três categorias:

- Transporte público
- Carro
- A pé

Defina duas variáveis dummies d_1 e d_2 :

- $d_1 = 1$ para Transporte Público, 0 caso contrário
- $d_2 = 1$ para Carro, 0 caso contrário
- O meio “a pé” é indicado quando $d_1 = d_2 = 0$

Formação

Suponha que a variável qualitativa seja formação universitária e as categorias sejam Bacharelado, Mestrado e Doutorado.

Use duas variáveis dummies para representar esta variável qualitativa.

$d1 = 1$ se mestrado, 0 caso contrário

$d2 = 1$ se doutorado, 0 caso contrário

Neste exemplo, bacharelado é a categoria de referência ao interpretar os dados.