

ANÁLISE DE REGRESSÃO

Regressão


A análise de regressão é um método que analisa a relação entre duas ou mais variáveis quantitativas.

Uma variável dependente (variável resposta), é influenciada por uma ou mais variáveis independentes (variáveis explicativas).

Usamos um modelo de regressão para prever os valores da variável dependente a partir das variáveis independentes.

Por que é importante?

- Modelos de previsão
- Modelos de classificação
- Machine Learning
- Entender a relação entre variáveis



CORRELAÇÃO



Correlação

A correlação descreve uma associação linear entre duas variáveis quantitativas.

A correlação pode ser:

- Positiva: quando uma aumenta, a outra aumenta
- Negativa: quando uma aumenta, a outra diminui

Coeficiente de Correlação



Correlação x Regressão

Correlação:

- As variáveis são relacionadas?
- Qual a direção (positiva ou negativa)?
- Qual o grau de correlação (fraca, forte, moderada)?

Regressão:

- Quanto uma variável muda se aumentarmos/diminuirmos a outra?
- Qual previsão/estimativa da variável?
- Quais variáveis formam o melhor modelo?

REGRESSÃO LINEAR SIMPLES

Regressão Linear Simples

Na regressão simples, temos uma variável dependente (y) e uma variável independente (x).

As variáveis possuem uma relação linear.

Queremos estimar um modelo populacional, na forma: $y = \beta_0 + \beta_1 x + \varepsilon$

A equação da regressão amostral é: $\hat{y} = b_0 + b_1 x$

Regressão Linear Simples

Com essa equação, podemos:

- Estimar um valor de y , baseado em um valor de x .
- Estimar a relação entre x e y (o quanto x influencia y).

Exemplo: Brigadeiros

Quero fazer uma encomenda de brigadeiros para uma festa.
O preço é 200 reais por cento, mais 20 reais de frete.

O frete é o custo fixo e o preço é o custo variável.

A equação do custo total seria:

$$\hat{y} = 20 + 200x$$

Onde x é a quantidade de brigadeiros (cento) e $\hat{y}$ é o custo total estimado.

PREVISÃO

Exemplo: Preço de uma casa

O preço de uma casa depende em parte do número de metros quadrados.


O preço é a variável dependente (y) e número de metros quadrados é a variável independente (x).

Qual o preço médio de uma casa com 150 metros quadrados?

Exemplo: Preço de uma casa

Primeiro, precisamos ver se existe uma relação linear entre essas variáveis.

Podemos ver a associação linear e o coeficiente de correlação r é 0,77.



Exemplo: Preço de uma casa

Ao analisar os dados, obtemos a equação de regressão:

$$\hat{y} = 172.691 + 1925x$$

onde x é o número de metros quadrados e $\hat{y}$ é o preço estimado.

Exemplo: Preço de uma casa

$$\hat{y} = 172.691 + 1925x$$

Qual o preço médio de uma casa com 150 metros quadrados?

$$\hat{y} = 172.691 + 1925 \cdot 150 = 461.441$$

O preço médio de uma casa com 150 metros quadrados é de R\$461.441.

INTERPRETAÇÃO DOS COEFICIENTES

Regressão Linear Simples

$$\hat{y} = b_0 + b_1x$$

b_0 é o intercepto da reta com y.

- É o valor de y quando $x = 0$.

b_1 é a inclinação da reta em relação à x.

- É a mudança que acontece em y conforme aumentamos 1 unidade em x.

Exemplo: Preço de uma casa

$$\hat{y} = 172.691 + 1925x$$

b_0 é o intercepto da reta com y (valor de y quando $x = 0$)

- Interpretar b_0 não faz sentido (preço de uma casa com zero m^2)
- Custo fixo: R\$172.691

b_1 é a inclinação da reta em relação à x (b_1 nos dá o valor de y por 1 unidade de x)

- O preço da casa é de R\$1.925 por m^2

ANÁLISE DE RESÍDUOS

Resíduos

O resíduo é o valor real menos o valor previsto pela equação de regressão:

$$e = \text{Real} - \text{Previsto} = y - \hat{y}$$

Exemplo: Encontre o valor residual de uma casa de 150 metros quadrados que foi vendida por R\$350.000.


$$\hat{y} = 172.691 + 1925(150) = 461.441$$

$$e = y - \hat{y} = 350.000 - 461.441 = -111.441$$

Resíduos

A linha de melhor ajuste torna os quadrados dos resíduos os menores possíveis.

A escolha de b_0 e b_1 minimiza a soma dos quadrados dos resíduos (Método dos Mínimos Quadrados).



Análise dos Resíduos

Precisamos fazer 3 verificações chamadas de Análise dos Resíduos.

São suposições para mostrar que sua regressão é confiável.

Essas suposições se baseiam no erro ε , porém esses valores não podem ser observados porque existem apenas na população.

Mas podemos analisar os resíduos, $e = y - \hat{y}$.



Análise dos Resíduos

- Normal: Os resíduos são normalmente distribuídos.
- Variância constante: Todos os resíduos têm variâncias similares (homoscedasticidade).
- Independência: Os erros são independentes uns dos outros.

Normalidade dos Resíduos

Verificamos se os resíduos são normalmente distribuídos:

- Histograma dos resíduos
- Gráfico de quantis (Q-Q plot)



Normalidade dos Resíduos

Também podemos fazer teste de normalidade, como:

- Kolmogorov–Smirnov
- Shapiro–Wilk

Caso uma possível falta de normalidade seja detectada, é necessário satisfazer a condição de tamanho de amostra para usar o Teorema do Limite Central.

Variação do Resíduo


Mostra a variação que permanece nos dados após considerar a relação linear definida pela linha ajustada.

O gráfico deve mostrar os resíduos contra a variável independente x para verificar se há algum padrão.

A falta de um padrão no gráfico sugere variância constante.

Gráfico de Resíduos

Exemplos de padrões no gráfico de resíduos:



Soluções

Caso não haja evidências de variância constante:


- Reconstrua o modelo com outras variáveis independentes
- Use transformações não lineares
- Use um modelo de regressão não linear

Independência

Para verificar a independência, plote os resíduos contra as variáveis temporais ou espaciais.

A falta de padrão sugere independência.

Caso uma possível falta de independência seja detectada, é necessário usar uma técnica específica de séries temporais para analisar essas variáveis.



INFERÊNCIA NA REGRESSÃO

Teste de Hipóteses

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Queremos testar se os coeficientes são significativos para estimar y .

Testamos se o coeficiente é significativamente diferente de zero, olhando para o p-valor e comparando com alfa.

Intervalo de Confiança

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Também podemos testar se os coeficientes são significativos pelo intervalo de confiança.

Interpretação:

Se houver 0 no intervalo: não é significativo.

Se não houver 0 no intervalo: é significativo.

Intervalo de Predição


Intervalo de predição: um intervalo de valores y para um valor de x .

Um intervalo de predição difere de um intervalo de confiança porque dá um intervalo da localização de uma nova observação em vez de um parâmetro de uma população.

$$\hat{y} = 172.691 + 1925(150) = 461.441$$

Intervalo de predição: [281.366, 641.554]

Intervalo de Predição




PADRÕES NÃO LINEARES

Padrões não lineares

Falamos de correlação e regressão, assumindo que há uma linearidade entre as variáveis.

Mas o que acontece se elas têm uma relação curvilínea?



Padrões não lineares


Neste caso, podemos fazer uma transformação em uma (ou ambas) variáveis.

E, assim, podemos fazer uma análise de regressão da mesma forma como visto anteriormente.

Escolhendo uma transformação

O processo de escolha da transformação ideal é geralmente iterativo.

Uma dica é usar o gráfico abaixo. Encontre o formato visto no gráfico de dispersão para encontrar a transformação apropriada.





Transformação Logarítmica

Exemplo: Quanto uma rede de supermercados deveria cobrar por uma marca de ração para animais de estimação?

São analisados o volume de vendas e o preço médio de latinhas de ração por 2 anos (104 semanas).



Transformação Logarítmica



Transformação Logarítmica

Neste caso, as duas variáveis são transformadas (log-log) e obtemos:

$$\log_e (\text{Volume de Vendas}) = 11.05 - 2.44 \log_e \text{ Preço}$$



Transformação Logarítmica

Comparando os resultados da regressão linear com a equação log-log.

Average Price (\$)	Linear Equation Estimated Sales	Log-Log Equation	
		Estimated Sales, Log scale	Estimated Sales
0.80	$190,480 - 125,190 \times 0.8 \approx 90,328$	$11.05 - 2.442 \times \log_e(0.8) \approx 11.594$	$\exp(11.594) \approx 108,445$
0.90	$190,480 - 125,190 \times 0.9 \approx 77,809$	$11.05 - 2.442 \times \log_e(0.9) \approx 11.307$	$\exp(11.307) \approx 81,389$
1.00	$190,480 - 125,190 \times 1.0 \approx 65,290$	$11.05 - 2.422 \times \log_e(1.0) \approx 11.050$	$\exp(11.050) \approx 62,944$
1.10	$190,480 - 125,190 \times 1.1 \approx 52,771$	$11.05 - 2.422 \times \log_e(1.1) \approx 10.817$	$\exp(10.817) \approx 49,861$
1.20	$190,480 - 125,190 \times 1.2 \approx 40,252$	$11.05 - 2.422 \times \log_e(1.2) \approx 10.605$	$\exp(10.605) \approx 40,336$

Transformação Logarítmica

A equação log-log mostra que os clientes são mais sensíveis ao preço quando os preços são mais baixos.

Por exemplo, mudar o preço médio de \$0,80 para \$0,90 leva a uma queda de mais de 27.000 latas no volume estimado de vendas.

Por outro lado, uma mudança de \$1,10 para \$1,20 leva a uma queda menor nas vendas, de cerca de 9.500 latas.

ELASTICIDADE

Elasticidade

É a medida que relaciona % de variação em x com % de variação em y .

É a inclinação (b_1) em uma equação de regressão log-log.

Podemos usar a elasticidade para encontrar o preço ideal de ração para essa rede de supermercados.

Vamos assumir que o custo de uma lata é de \$0,60.

Elasticidade

$$\log_e (\text{Volume de Vendas}) = 11.05 - 2.44 \log_e \text{Preço}$$

$$\text{Elasticidade} = -2,44$$

$$\text{Preço ideal} = \text{Custo} * \left(\frac{\text{Elasticidade}}{\text{Elasticidade} + 1} \right)$$

$$\text{Preço ideal} = 0,60 * \left(\frac{-2,44}{-2,44 + 1} \right) = 1,02$$

O lucro é maximizado ao preço de \$1,02 por lata.

ANSCOMBE

Anscombe

- 4 conjuntos de dados
- x média 9 e y média 7,5
- Equação da regressão: $y = 3 + 0,5x$
- Erro padrão: 0,118
- Teste t: 4,24
- $R^2 = 0,67$

Table 1.1 Anscombe's quartet of data sets

I		II		III		IV	
X	Y	X	Y	X	Y	X	Y
10.0	8.04	10.0	9.14	10.0	7.46	8.0	6.58
8.0	6.95	8.0	8.14	8.0	6.77	8.0	5.76
13.0	7.58	13.0	8.74	13.0	12.74	8.0	7.71
9.0	8.81	9.0	8.77	9.0	7.11	8.0	8.84
11.0	8.33	11.0	9.26	11.0	7.81	8.0	8.47
14.0	9.96	14.0	8.10	14.0	8.84	8.0	7.04
6.0	7.24	6.0	6.13	6.0	6.08	8.0	5.25
4.0	4.26	4.0	3.10	4.0	5.39	19.0	12.50
12.0	10.84	12.0	9.13	12.0	8.15	8.0	5.56
7.0	4.82	7.0	7.26	7.0	6.42	8.0	7.91
5.0	5.68	5.0	4.74	5.0	5.73	8.0	6.89
9.0	7.5	9.0	7.5	9.0	7.5	9.0	7.5


Notes: Each data set has 11 observations; the means are shown in the bottom row. Every regression line is $Y = 3 + 0.5X$; the standard error of the slope coefficient is 0.118 and its t -statistic is 4.24.

In every case, $R^2 = 0.67$


Source: Anscombe 1973

Anscombe

- 4 conjuntos de dados
- x média 9 e y média 7,5
- Equação da regressão: $y = 3 + 0,5x$
- Erro padrão: 0,118
- Teste t: 4,24
- $R^2 = 0,67$



Datasaurus Dozen



X Mean: 54.2659224
Y Mean: 47.8313999
X SD : 16.7649829
Y SD : 26.9342120
Corr. : -0.0642526