

REGRESSÃO LOGÍSTICA

Regressão Logística

A regressão logística é um método estatístico utilizado para modelar a probabilidade de ocorrência de um evento.

Diferente da regressão linear, a logística é utilizada quando a variável dependente é categórica.

Regressão logística binária: a variável dependente é binária, ou seja, tem dois possíveis resultados (0 ou 1, sucesso ou fracasso).

Importância

Predição de eventos binários: Ideal para prever a probabilidade de ocorrência de um evento como aprovação/reprovação, compra/não compra.

Interpretação intuitiva: O resultado é uma probabilidade que facilita a interpretação dos resultados.

Pouco explorada: Pode ser utilizada em diversas áreas como medicina, marketing, finanças, etc.

Aplicações

Medicina: Previsão de doenças com base em fatores de risco.

Marketing: Probabilidade de um cliente comprar um produto.

Finanças: Risco de inadimplência de um empréstimo.

Recursos Humanos: Probabilidade de um funcionário deixar a empresa.

REGRESSÃO LINEAR X LOGÍSTICA

RECAPITULANDO: REGRESSÃO LINEAR

Regressão Linear

Podemos estimar o impacto do tamanho de uma casa no seu preço:


$$y = \beta_0 + \beta_1 x + \varepsilon$$

$$\widehat{\text{Preço}} = 172.691 + 1925m^2$$

Qual é o preço estimado de uma casa com 150 metros ao quadrado?

$$\widehat{\text{Preço}} = 172.691 + 1925 * 150 = 461.441$$

Regressão Linear



REGRESSÃO LOGÍSTICA

Modelos binários


Quero estimar se uma pessoa terá diabetes.

Diabetes: sim ou não (variável categórica binária).

Avaliamos a probabilidade de que a variável dependente seja igual a 1.

Qual é a probabilidade de uma pessoa ter diabetes baseado no seu nível de açúcar no sangue (glicose)?

Regressão Logística



Regressão Logística

A regressão logística usa uma especificação não linear que restringe a probabilidade estimada em $[0, 1]$.

No entanto, isso tem um custo:

- A equação da regressão muda
- Interpretar os coeficientes não é simples

REGRESSÃO LOGÍSTICA

Regressão Logística

Função da distribuição logística:

$$\mu_{y|x} = \frac{1}{1 + e^{-y}}$$


Equação de regressão estimada:

$$\hat{p} = \frac{1}{1 + e^{-(b_0 + b_1 x)}}$$

Função linear:

$$\text{logit}(p) = \ln \left(\frac{p}{1-p} \right) = b_0 + b_1 x$$

↙ odds ratio (OR)



Exemplo

Uma pesquisadora usa o nível de glicose e a idade para estimar a probabilidade de um paciente ter diabetes.

Analizamos se a diabetes (1 = sim, 0 = não) é prevista pela glicose e idade.

	Coefficient	Standard Error	P-value	Odd Ratio	Lower 95%	Upper 95%
Intercept	-16.816	6.6242	0.011	4.97E-08	1.14E-13	0.02164
idade	0.060	0.2441	0.806	1.0619	0.6581	1.7134
glicose	0.115	0.1014	0.258	1.1217	0.9194	1.3684

Os coeficientes das variáveis independentes são positivos.
Há uma influência positiva na probabilidade prevista de ter diabetes.

PREVISÃO

Previsão

Para uma pessoa com 60 anos e 130 mg/dL de glicose, a probabilidade prevista de ter diabetes é:

$$\hat{p} = \frac{1}{1 + \exp(-(-16,816 + 0,06 \cdot 60 + 0,115 \cdot 130))} = 0,85$$

	Coefficient	Standard Error	P-value	Odd Ratio	Lower 95%	Upper 95%
Intercept	-16.816	6.6242	0.011	4.97E-08	1.14E-13	0.02164
idade	0.060	0.2441	0.806	1.0619	0.6581	1.7134
glicose	0.115	0.1014	0.258	1.1217	0.9194	1.3684

INTERPRETAÇÃO DOS COEFICIENTES

Interpretando

Coeficientes (β): Representam o log-odds da variável independente no modelo.

Para analisar o efeito de uma unidade adicional em X na probabilidade do evento, precisamos calcular a exponencial de β .

Interpretando a Idade

$$\beta_1 = 0,060$$

$$e^{\beta_1} = 1,0619$$

$$e^{\beta_1} - 1 = 0,0619 \text{ ou } 6,19\%$$

	Coefficient	Standard Error	P-value	Odd Ratio
Intercept	-16.816	6.6242	0.011	4.97E-08
idade	0.060	0.2441	0.806	1.0619
glicose	0.115	0.1014	0.258	1.1217

Para cada ano adicional na idade (x1), estimamos que a chance de ter diabetes aumente em 6,19%, comparando pessoas com o mesmo índice de glicose no sangue.

Interpretando a Glicose

$$\beta_2 = 0,115$$

$$e^{\beta_2} = 1,1217$$

$$e^{\beta_2} - 1 = 0,1217 \text{ ou } 12,17\%$$

	Coefficient	Standard Error	P-value	Odd Ratio
Intercept	-16.816	6.6242	0.011	4.97E-08
idade	0.060	0.2441	0.806	1.0619
glicose	0.115	0.1014	0.258	1.1217

Para cada aumento de 1 mg/dL no índice de glicose (x2), estimamos que a chance de ter diabetes aumente em 12,17%, comparando pessoas com a mesma idade.

OUTRO PROBLEMA

Exemplo

Uma universidade usa o SAT e o GPA do ensino médio como critérios primários para admissão.

Analizamos se a admissão do aluno (1 = sim, 0 = não) é prevista pelo GPA e SAT.

	Coefficient	Standard Error	P-value	Odds Ratio	Lower 95%	Upper 95%
Intercept	-19.48	8.291743	0.018816	3.47E-09	3.04E-16	0.039673
SAT	0.0065	0.002531	0.00998	1.006543	1.001562	1.01155
GPA	2.78	1.408096	0.04835	16.11861	1.020361	254.6251

Interpretando o SAT

$$\beta_1 = 0,0065$$

$$e^{\beta_1} = 1,0065$$

$$e^{\beta_1} - 1 = 0,0065 \text{ ou } 0,65\%$$

	Coefficient	Standard Error	P-value	Odds Ratio
Intercept	-19.48	8.291743	0.018816	3.47E-09
SAT	0.0065	0.002531	0.00998	1.006543
GPA	2.78	1.408096	0.04835	16.11861

Para cada ponto adicional no SAT (x1), estimamos que a chance de ser admitido aumente em 0,65%, comparando estudantes com o mesmo GPA.

Porém, a amplitude do SAT é de 1280 a 2250.

Interpretando o SAT

Analizando o impacto para uma unidade c de mudança $= e^{c \cdot \beta_1} - 1$

$$c \cdot \beta_1 = 100 \cdot 0,0065 = 0,65$$

$$e^{c \cdot \beta_1} = 1,919$$

$$e^{c \cdot \beta_1} - 1 = 0,919 \text{ ou } 91,9\%$$

Para cada 100 pontos adicionais no SAT (x1), estimamos que a chance de ser admitido aumenta em 91,9%, comparando estudantes com o mesmo GPA.

Interpretando o GPA

$$\beta_2 = 2,78$$

$$e^{\beta_2} = 16,12$$

$$e^{\beta_2} - 1 = 15,12 \text{ ou } 1512\%$$

	Coefficient	Standard Error	P-value	Odds Ratio
Intercept	-19.48	8.291743	0.018816	3.47E-09
SAT	0.0065	0.002531	0.00998	1.006543
GPA	2.78	1.408096	0.04835	16.11861

Para cada ponto adicional no GPA (x2), estimamos que a chance de ser admitido aumente em 1512%, comparando estudantes com o mesmo SAT.

Porém, a amplitude do GPA é de 2.28 a 4.

Interpretando o GPA

Analizando o impacto para uma unidade c de mudança $= e^{c \cdot \beta_2} - 1$

$$c \cdot \beta_2 = 0,1 \cdot 2,78 = 0,278$$

$$e^{c \cdot \beta_2} = 1,32$$

$$e^{c \cdot \beta_2} - 1 = 0,32 \text{ ou } 32\%$$

Para cada 0,1 ponto adicional no GPA (x2), estimamos que a chance de ser admitido aumentem em 32%, comparando estudantes com o mesmo SAT.

SUPOSIÇÕES

Suposições

- Independência das Observações
- Linearidade no Logit
- Ausência de Multicolinearidade
- Medidas de Adequação do Modelo

MEDIDAS DE ADEQUAÇÃO

Adequação do Modelo

A adequação geral do modelo pode ser avaliada usando o teste de deviance e o pseudo R^2 .

Para determinar se os coeficientes têm um efeito significativo na variável dependente, realizamos testes de hipótese para cada coeficiente.

- Teste de Wald ao invés do teste t (p-valor)

Pseudo R^2

É uma forma de quantificar o quanto da variabilidade da variável dependente é explicada pelo modelo (similar ao R^2 na regressão linear).

$$\text{McFadden's } R^2 = 1 - \frac{\ln(L_{\text{completo}})}{\ln(L_{\text{nulo}})}$$

Teste de Wald

É o teste para cada coeficiente na regressão logística.


Calculado:

$$z = \frac{b_i}{\text{ep}(b_i)}$$

Interpretamos o p-valor associado ao teste z da mesma forma que já estudamos.

AVALIAÇÃO DE PERFORMANCE

Performance do Modelo



Performance do Modelo

- Acurácia (proporção de previsões corretas)
- Precisão (proporção de previsões positivas corretas em relação ao total de previsões positivas feitas pelo modelo)
- Sensibilidade/Recall (proporção de previsões positivas corretas em relação ao total de casos reais positivos)
- F1 Score (média harmônica entre precisão e sensibilidade)
- Área abaixo da curva ROC (AUC ROC)

Matriz de confusão

		Valor Predito	
		Sim	Não
Real	Sim	Verdadeiro Positivo (TP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (TN)

Métricas

- Acurácia = $\frac{TP + TN}{TP + TN + FP + FN}$
- Precisão = $\frac{TP}{TP + FP}$
- Sensibilidade/Recall = $\frac{TP}{TP + FN}$
- F1 Score = $2 \cdot \frac{\text{Precisão} \cdot \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}}$

		Valor Predito	
		Sim	Não
Real	Sim	Verdadeiro Positivo (TP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (TN)

Métricas

F1 Score mede o equilíbrio entre a precisão e a sensibilidade.

O F1-Score varia de 0 a 1:

- Um F1-Score de 1 indica o melhor desempenho possível (alta precisão e alta sensibilidade).
- Um F1-Score de 0 indica o pior desempenho possível (baixa precisão e baixa sensibilidade).

AUC ROC

Área abaixo da curva ROC (AUC ROC)

- ROC (Receiver Operating Characteristic): um gráfico que mostra o desempenho de um modelo de classificação ao longo de todos os pontos de corte possíveis.
- Mostra a taxa de verdadeiros positivos (sensibilidade) no eixo Y contra a taxa de falsos positivos ($1 - \text{especificidade}$) no eixo X.
- AUC: O valor da AUC varia de 0 a 1.
- O valor 0.5 indica que o modelo está performando de forma semelhante a um modelo aleatório.